

Evaluarea robusteții sistemelor de detecție a intruziunilor bazate pe învățare automată în fața perturbărilor adversariale

Absolvent: Ioana-Alina Neacșu | Coordonator științific: Șl.Dr.Ing. Eugen Richard Ardelean

1. Cerințele temei


Evaluarea empirică a robusteții unor clasificatoare de trafic de rețea în fața unor variante modificate deliberat ale traficului malițios. Tema impune: antrenarea unor clasificatoare multi-clasă pe setul public UNSW-NB15, în partiția oficială (175 341 de înregistrări de antrenare, 82 332 de testare, 42 de caracteristici predictive, 10 clase); generarea de variante perturbate prin transformări care păstrează funcționalitatea atacului (modificarea câmpului TTL, umplutură, dilatare temporală, reducerea ratei de conexiuni); măsurarea ratei de evaziune pe tipuri și niveluri de intensitate; analiza sensibilității modelelor la caracteristicile afectate; reantrenarea pe seturi augmentate cu variante perturbate, cu măsurarea câștigului și a costului; și o interfață de vizualizare și testare.

2. Soluții alese

Modele. Două ansambluri de arbori, Random Forest și XGBoost, plus o arhitectură Transformer adaptată datelor tabulare, implementată de la zero, pentru a contrasta două moduri fundamental diferite de a construi decizia.

Mulțimea perturbărilor admisibile. Vecinătatea metrică uzuală din literatura exemplilor adversariale a fost înlocuită cu o mulțime structurată, definită prin patru condiții: direcționalitate, limite relative la observația originală, imuabilitatea caracteristicilor aflate în afara controlului atacatorului și închiderea la dependențele dintre caracteristici. Ultima a necesitat un mecanism propriu de propagare, care recalculează exact caracteristicile derivate fără a cunoaște constantele sensorului. Caracteristica imposibil de reconstituit dintr-un flux izolat este raportată ca interval delimitat de două politici declarate, nu ca valoare unică obținută printr-o presupunere tacită.

Apărarea. Antrenare adversarială prin augmentare, nu prin gradient, întrucât gradientul ar presupune un acces la model pe care atacatorul nu îl are și nu se aplică ansamblurilor de arbori. Efectul este izolat printr-un grup de control antrenat pe același număr de exemple neperturbate, prin ponderi de clasă înghețate și printr-o mulțime comună de fluxuri, cu criterii de succes fixate înaintea rulării.



Structura funcțională a soluției. M4 se aplică de două ori, modelelor de referință și celor apărare. M6 este singurul modul terminal.

3. Rezultate obținute

Vulnerabilitatea. O singură modificare a valorii TTL, realizabilă prin configurarea socketului, duce modelul cu cel mai bun macro- $F1$ de la 0% la peste 50% evaziune; combinată cu umplutură și dilatare temporală, rata ajunge la aproape 97%. Celelalte transformări lasă evaziunea sub 1,3% la orice intensitate.

Cauza. Valoarea TTL este un artefact al mediului de captură, nu o proprietate a atacurilor: în partiția de antrenare, 70,5% din traficul legitim are valoarea 31, iar fiecare clasă de atac are dominantă 254. Mărimea introdusă în lucrare, *fracțiunea accesibilă* ρ , arată că modelele se ordonează invers față de rezistența lor: 84,1% la XGBoost, 53,6% la Random Forest, 26,0% la Transformer. Rezistența Transformer nu provine dintr-o reprezentare mai bună, ci din dependența de o caracteristică generată de victimă.

Apărarea. Reantrenarea reduce evaziunea în cel mai rău caz sub 0,5% la toate trei modelele, de la valori între 71% și 97%, iar câștigul se menține față de grupul de control. Costul este sub 0,023 de macro- $F1$, dar

concentrat: clasa cea mai rară pierde între 0,075 și 0,127. Analiza sensibilității aplicată modelelor apărute arată *prin ce* s-a obținut rezultatul: TTL-ul sursă cade de pe locul 1 pe locurile 38–41 din 42, iar ρ scade la 7–19%. Modelele nu au memorat perturbările, au abandonat caracteristica. Invarianța se transferă însă la o familie nevăzută doar la unul dintre cele trei modele, iar dependența se mută pe TTL-ul de răspuns, tot un artefact de captură.

4. Testări și verificări

Validarea este organizată pe patru niveluri: determinism, validitate a variantelor, testare negativă a suitei de validare și invarianți de capăt la capăt. Verificările executate:

- varianta neperturbată reproduce predicțiile de referință rând cu rând, pe întreaga partiție de testare, și produce evaziune nulă;
- grupul de referință al antrenării adversariale reproduce modelele înghețate: 0 nepotriviri din 82 332 la toate cele trei familii, iar rețeaua coincide și pe traiectoria de optimizare, până la a patra zecimală;
- lanțul de măsurare al apărării reproduce toate cifrele publicate anterior, cu o abatere maximă de 0,0000 puncte procentuale pe 28 de variante;
- eroarea reziduală a propagării dependențelor este de ordinul 10^{-15} ;
- mulțimea comună acoperă între 96,3% și 99,3% din fluxurile de atac, deci comparațiile nu se fac pe un rest îngust;
- suita respinge efectiv variante invalide construite intenționat.

5. Contribuții personale

Formularea mulțimii perturbărilor admisibile și mecanismul de propagare care o face realizabilă. Tratarea explicită a caracteristicii nereconstituibile prin raportare sub formă de interval. Introducerea fracțiunii accesibile ρ , care leagă cantitativ importanța caracteristicilor de rata de evaziune, exprimându-le în aceleași unități. Protocolul experimental al apărării, cu grup de control, ponderi înghețate, mulțime comună și criterii pre-înregistrate. Grupul antrenat cu o familie exclusă deliberat, care a arătat că robustețea obținută nu se generalizează. Aplicarea analizei de sensibilitate modelelor apărute, care a stabilit mecanismul apărării. Implementarea de la zero a arhitecturii Transformer și a interfeței interactive, construită din aceleași primitive validate ca experimentele sistematice.

6. Surse de documentare

Lucrarea se sprijină pe 25 de referințe, grupate pe patru direcții. **Seturi de date:** analiza comparativă a lui Ring et al., lucrarea de introducere a setului UNSW-NB15 a lui Moustafa și Slay, CIC-IDS-2017, analiza critică a setului KDD CUP 99 și studiul lui Liu et al. asupra erorilor din seturile CIC. **Modele de clasificare:** Breiman, Chen și Guestrin, plus studii aplicate de detecție a intruziunilor. **Arhitecturi neuronale:** lucrarea de referință a mecanismului de atenție, adaptarea la date tabulare a lui Gorishniy et al., pe care se bazează implementarea, și lucrări de detecție bazate pe transformere. **Învățare adversarială:** Szegedy et al. și Goodfellow et al. pentru originea exemplelor adversariale, Madry et al. pentru formularea min-max a antrenării adversariale, studii de evaziune specifice traficului de rețea și RFC 6274 pentru semantica câmpului TTL.