



SINTEZA

proiectului de diplomă cu titlul:

EVALUAREA ROBUSTEȚII SISTEMELOR DE DETECȚIE A INTRUZIUNILOR BAZATE PE ÎNVĂȚARE AUTOMATĂ ÎN FAȚA PERTURBĂRIILOR ADVERSARIALE

Autor: **Ioana-Alina NEACȘU**Coordonator: **Șl.Dr.Ing. Eugen Richard ARDELEAN**

1. Cerințele temei

Evaluarea empirică a robusteții unor clasificatoare de trafic de rețea în fața unor variante modificate deliberat ale traficului malițios. Tema impune: antrenarea unor clasificatoare multi-clasă pe UNSW-NB15 [1], în partiția oficială (175 341 de înregistrări de antrenare, 82 332 de testare, 42 de caracteristici predictive, 10 clase), generarea de variante perturbate prin transformări asupra traficului, precum modificarea valorii TTL [7], umplutura, dilatarea temporală și reducerea ratei de conexiuni, măsurarea evaziunii pe tipuri și niveluri, analiza sensibilității, reantrenarea pe seturi augmentate, cu măsurarea câștigului și a costului, plus o interfață de vizualizare și testare.

2. Soluții alese

Modele. Două ansambluri de arbori, Random Forest [2] și XGBoost [3], plus o arhitectură Transformer adaptată datelor tabulare [4], implementată de la zero, pentru a contrasta două moduri fundamental diferite de a construi decizia.

Mulțimea perturbărilor admisibile. Perturbările sunt delimitate prin patru condiții: direcționalitate, limite relative la observația originală, imuabilitatea caracteristicilor din afara controlului atacatorului și închiderea la dependențele dintre caracteristici. Ultima a necesitat un mecanism propriu de propagare, care recalculează exact caracteristicile derivate fără a cunoaște constantele senzorului. Rezultatele care depind de caracteristica nereconstituibilă sunt raportate sub formă de interval.

Apărarea. Antrenare adversarială prin augmentare [5, 6], nu prin gradient, întrucât gradientul ar presupune un acces la model pe care atacatorul nu îl are și nu se aplică arborilor. Efectul este izolat printr-un grup de control antrenat pe același număr de exemple neperturbate, prin ponderi de clasă înghețate și printr-o mulțime comună de fluxuri, cu criterii fixate înaintea rulării.




Figura 1. Structura funcțională a soluției.

3. Rezultate obținute

Vulnerabilitatea. O singură modificare a valorii TTL duce modelul cu cel mai bun macro- $F1$ de la 0% la peste 50% evaziune, iar combinată cu umplură și dilatare temporală, rata ajunge la aproape 97%. Celelalte transformări lasă evaziunea sub 1,3% la orice intensitate.

Cauza. Valoarea TTL funcționează ca un artefact al mediului de captură în UNSW-NB15, nu ca o proprietate a atacurilor: în partiția de antrenare, 70,5% din traficul legitim are valoarea 31, iar fiecare clasă de atac are dominantă 254. Mărimea introdusă în lucrare, fracțiunea accesibilă ρ , arată că modelele se ordonează invers față de rezistența lor: 84,1% la XGBoost, 53,6% la Random Forest, 26,0% la Transformer. Rezistența aparent superioară a Transformerului este explicată în mare măsură de dependența de o caracteristică generată de victimă.

Apărarea. Reantrenarea reduce evaziunea în cel mai rău caz sub 0,5% la toate trei modelele, de la valori între 71% și 97%, iar câștigul se menține față de grupul de control. Costul este sub 0,023 de macro- $F1$, dar concentrat: clasa cea mai rară pierde între 0,075 și 0,127. Analiza sensibilității aplicată modelelor apărute arată prin ce s-a obținut rezultatul: TTL-ul sursă coboară de pe primele două poziții pe locurile 38–41 din 42, iar ρ scade la 7–19%.

4. Testări și verificări

Verificarea a urmărit patru aspecte: determinismul rulărilor, validitatea variantelor perturbate, capacitatea de respingere a variantelor invalide și corectitudinea întregului lanț. Rezultatele:

- execuția deterministă a fost verificată prin rulări repetate;
- cele 28 de variante au trecut 1 259 de verificări de validitate, fără nicio încălcare, iar recalcularea caracteristicilor derivate a păstrat relațiile dintre ele cu o eroare de ordinul 10^{-15} ;
- toate variantele construite intenționat cu încălcarea constrângerilor au fost respinse de verificări;
- varianta care nu modifică nimic a reprodus exact predicțiile modelelor de referință;
- codul de evaluare folosit în etapa adversarială a reprodus, pe modelele de referință, aceleași rate ca măsurarea inițială;
- seturile utilizate pentru compararea modelelor au inclus între 96,3% și 99,3% dintre fluxurile de atac.

5. Contribuții personale

Formularea mulțimii perturbărilor admisibile și mecanismul de propagare care păstrează consistența internă a variantelor generate. Raportarea sub formă de interval a caracteristicii nereconstituibile. Introducerea fracțiunii accesibile ρ , care leagă cantitativ importanța caracteristicilor de rata de evaziune. Protocolul experimental al apărării, cu grup de control, ponderi înghețate, mulțime comună și criterii stabilite și consemnate înaintea rulării. Grupul antrenat cu o familie exclusă deliberat, care a arătat că robustețea nu se generalizează. Aplicarea analizei de sensibilitate modelelor apărute, care a stabilit mecanismul apărării.

6. Surse de documentare

- [1] N. Moustafa, J. Slay, „UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems”, MilCIS, 2015.
- [2] L. Breiman, „Random Forests”, *Machine Learning*, vol. 45, nr. 1, 2001.
- [3] T. Chen, C. Guestrin, „XGBoost: A Scalable Tree Boosting System”, ACM SIGKDD, 2016.
- [4] Y. Gorishniy et al., „Revisiting Deep Learning Models for Tabular Data”, NeurIPS, vol. 34, 2021.
- [5] I. J. Goodfellow, J. Shlens, C. Szegedy, „Explaining and Harnessing Adversarial Examples”, ICLR, 2015.
- [6] A. Madry et al., „Towards Deep Learning Models Resistant to Adversarial Attacks”, ICLR, 2018.
- [7] F. Gont, „Security Assessment of the Internet Protocol Version 4”, IETF RFC 6274, 2011.

Data: _____

Autor _____

Coordonator _____