



## SINTEZA

proiectului de diplomă cu titlul:

EVALUAREA ROBUSTEȚII SISTEMELOR DE DETECȚIE A INTRUZIUNILOR  
BAZATE PE ÎNVĂȚARE AUTOMATĂ ÎN FAȚA PERTURBĂRILOR ADVERSARIALEAutor: **Ioana-Alina NEACȘU**Coordonator: **Șl.Dr.Ing. Eugen Richard ARDELEAN**

## 1. Cerințele temei

Evaluarea empirică a robusteții unor clasificatoare de trafic de rețea în fața unor variante modificate deliberat ale traficului malițios. Tema impune: antrenarea unor clasificatoare multi-clasă pe UNSW-NB15 [1], în partiția oficială (175 341 de înregistrări de antrenare, 82 332 de testare, 42 de caracteristici predictive, 10 clase), generarea de variante perturbate prin transformări asupra traficului, precum modificarea valorii TTL [7], umplutura, dilatarea temporală și reducerea ratei de conexiuni, măsurarea evaziunii pe tipuri și niveluri, analiza sensibilității, reantrenarea pe seturi augmentate, cu măsurarea câștigului și a costului, plus o interfață de vizualizare și testare.

## 2. Soluții alese

**Modele.** Două ansambluri de arbori, Random Forest [2] și XGBoost [3], plus o arhitectură Transformer adaptată datelor tabulare [4], implementată de la zero, pentru a contrasta două moduri fundamental diferite de a construi decizia.

**Mulțimea perturbărilor admisibile.** O modificare contează doar dacă atacatorul chiar o poate produce. Perturbările sunt deci limitate prin patru condiții care exclud ce nu se poate face: atacatorul își controlează doar propriile pachete, modificările rămân proporționale cu fluxul de la care pleacă, ce definește identitatea atacului rămâne nemodificat, iar tot ce depinde de valorile schimbate se recalculează, altfel fluxul ar deveni incoerent. Ultima condiție a cerut un mecanism propriu de propagare, care reface caracteristicile derivate fără să cunoască constantele senzorului. Rezultatele care depind de caracteristica nereconstituibilă sunt raportate sub formă de interval.

**Apărarea.** Antrenare adversarială prin augmentare [5, 6], nu prin gradient, întrucât gradientul ar presupune un acces la model pe care atacatorul nu îl are și nu se aplică arborilor. Augmentarea schimbă însă mai multe lucruri deodată, nu doar prezența perturbării. Ca să rămână doar efectul ei, grupul de control primește tot atâtea copii, dar nemodificate, ponderile de clasă sunt identice la toate grupurile, ratele se calculează pe aceeași mulțime de fluxuri, iar pragurile de succes sunt fixate înainte de rulare.




Figura 1. Structura funcțională a soluției.

### 3. Rezultate obținute

**Vulnerabilitatea.** O singură modificare a valorii TTL duce modelul cu cel mai bun macro- $F1$  de la 0% la peste 50% evaziune, iar combinată cu umplutură și dilatare temporală, rata ajunge la aproape 97%. Celelalte transformări lasă evaziunea sub 1,3% la orice intensitate.

**Cauza.** Valoarea TTL funcționează ca un artefact al mediului de captură în UNSW-NB15, nu ca o proprietate a atacurilor: în partiția de antrenare, 70,5% din traficul legitim are TTL-ul 31, în timp ce în fiecare clasă de atac domină valoarea 254. Se poate deci măsura cât de expus este un model : fracțiunea accesibilă  $\rho$ , introdusă în lucrare, arată ce parte din capacitatea lui de detecție se sprijină pe caracteristici aflate la îndemâna atacatorului. XGBoost are 84,1%, Random Forest 53,6%, iar Transformer 26,0% (ordinea inversă a rezistenței observate). Transformer cedează mai puțin nu fiindcă ar reprezenta mai bine atacurile, ci fiindcă se sprijină pe o caracteristică pe care o generează victima și pe care atacatorul nu o poate atinge.

**Apărarea.** Reantrenarea reduce evaziunea în cel mai rău caz sub 0,5% la toate trei modelele, de la valori între 71% și 97%, iar câștigul se menține față de grupul de control. Costul este sub 0,023 de macro- $F1$ , dar concentrat: clasa cea mai rară pierde între 0,075 și 0,127. Analiza sensibilității aplicată modelelor apărute arată prin ce s-a obținut rezultatul: TTL-ul sursă coboară de pe primele două poziții pe locurile 38-41 din 42, iar  $\rho$  scade la 7-19%.

### 4. Testări și verificări

Verificarea a urmărit patru aspecte: determinismul rulărilor, validitatea variantelor perturbate, capacitatea de respingere a variantelor invalide și corectitudinea întregului lanț. Rezultatele:

- execuția deterministă a fost verificată prin rulări repetate;
- cele 28 de variante au trecut 1 259 de verificări de validitate, fără nicio încălcare, iar recalcularea caracteristicilor derivate a păstrat relațiile dintre ele;
- toate variantele construite intenționat cu încălcarea constrângerilor au fost respinse de verificări;
- varianta care nu modifică nimic a reprodus predicțiile modelelor de referință;
- codul de evaluare folosit în etapa adversarială a reprodus, pe modelele de referință, aceleași rate ca măsurarea inițială;
- seturile utilizate pentru compararea modelelor au inclus între 96,3% și 99,3% dintre fluxurile de atac.

### 5. Contribuții personale

Formularea mulțimii perturbărilor admisibile și mecanismul de propagare care păstrează consistența internă a variantelor generate. Raportarea sub formă de interval a caracteristicii nereconstituibile. Introducerea fracțiunii accesibile  $\rho$ , care leagă cantitativ importanța caracteristicilor de rata de evaziune. Protocolul experimental al apărării, cu grup de control, ponderi de clasă identice pe toate grupurile, mulțime comună și criterii stabilite și consemnate înaintea rulării. Analiza de sensibilitate aplicată modelelor apărute, care a explicat mecanismul: ele au abandonat caracteristica accesibilă atacatorului, în loc să memoreze perturbările.

### 6. Surse de documentare

- [1] N. Moustafa, J. Slay, „UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems”, MilCIS, 2015.
- [2] L. Breiman, „Random Forests”, *Machine Learning*, vol. 45, nr. 1, 2001.
- [3] T. Chen, C. Guestrin, „XGBoost: A Scalable Tree Boosting System”, ACM SIGKDD, 2016.
- [4] Y. Gorishniy et al., „Revisiting Deep Learning Models for Tabular Data”, NeurIPS, vol. 34, 2021.
- [5] I. J. Goodfellow, J. Shlens, C. Szegedy, „Explaining and Harnessing Adversarial Examples”, ICLR, 2015.
- [6] A. Madry et al., „Towards Deep Learning Models Resistant to Adversarial Attacks”, ICLR, 2018.
- [7] F. Gont, „Security Assessment of the Internet Protocol Version 4”, IETF RFC 6274, 2011.

Data: \_\_\_\_\_

Autor \_\_\_\_\_

Coordonator \_\_\_\_\_